有限前瞻在线集装箱重定位问题中的参数高效策略适配：问题定义

匿名论文草稿

摘要

本文形式化定义一个受限的单贝位在线集装箱重定位问题。在该问题中，决策策略能够观测当前目标箱以及有限数量的后续目标箱。在此基础上，本文进一步定义本项目所研究的目标域策略适配问题：在固定源域策略主体参数的条件下，将其适配到更大规模的堆场布局，并在给定可训练参数预算和梯度更新预算的约束下最小化重定位次数。该定义明确规定策略可获得的信息、合法动作、环境转移过程、优化目标以及低秩适配约束。

1 问题定义

本文研究有限前瞻条件下，面向受限单贝位在线集装箱重定位问题的参数高效策略适配。信息揭示机制遵循在线集装箱重定位问题的基本设定，即集装箱的提取优先级并非从初始时刻起完全已知，而是随提取过程逐步揭示 [1]。本文所研究的问题不同于 Shin 等人 [2] 讨论的多贝位集装箱提取问题：本文将所有移动限制在单个贝位内，并以重定位次数为优化指标，而不是以岸桥作业时间为目标。

1.1 有限前瞻在线重定位问题

一个问题实例记为 $I = (X_0, \sigma; S, T, N)$，其中，$S$ 表示堆栈数量，T 表示每个堆栈允许的最大层数，N 表示集装箱总数。初始布局 X_0 给出各堆栈中集装箱自底向上的排列顺序。向量 $\sigma = (\sigma_1, \ldots, \sigma_N)$ 是全部集装箱的一个排列，用于规定集装箱的提取顺序。本文假设所有集装箱尺寸相同，提取过程中没有新的集装箱进入，并且任意时刻只能移动位于堆栈顶部的集装箱。所有集装箱必须严格按照 σ 给定的顺序提取。只有当前阻挡目标箱的集装箱允许被重定位；目标箱一旦可达，环境便立即将其提取。

堆场的物理布局对决策策略完全可见，但完整排列 σ 对策略不可见。令 n_t 表示在第 t 个重定位决策之前已经完成提取的集装箱数量。给定前瞻长度 H，该决策时刻向策略公开的信息窗口为

$$\mathcal{W}_t^H = \left(\sigma_{n_t+1}, \ldots, \sigma_{\min\{n_t+H+1, N\}}\right). \tag{1}$$

这里，H 表示除当前目标箱以外可见的未来目标箱数量。因此，当 $H = 20$ 时，策略最多可以获知 21 个集装箱的相对提取优先级。对于决策时刻 t 仍位于堆场中的任意集装箱 c，定义其公开相对优先级为

$$q_t(c) = \begin{cases} k, & c = \sigma_{n_t+k}, \quad 1 \le k \le \min\{H+1, N-n_t\}, \\ \perp, & \text{其他情况}, \end{cases} \tag{2}$$

其中，$\perp$ 是所有尚未公开优先级的集装箱共享的未知标记。因此，物理集装箱编号以及未公开集装箱之间的先后次序不得为策略提供任何额外信息。

在实现中，公开观测可以表示为一个“堆栈 – 层位”张量 $o_t \in \{-1, 0, 1, \ldots, H+1\}^{S\times T}$：

$$o_t(s,u) = \begin{cases} 0, & \text{堆栈 } s \text{ 的第 } u \text{ 层为空,} \\ q_t(c), & \text{该层存放集装箱 } c \text{ 且 } q_t(c) \neq \perp, \\ -1, & \text{该层存放优先级尚未公开的集装箱.} \end{cases} \tag{3}$$

各堆栈的当前高度、剩余容量以及当前目标箱所在的堆栈，均可由 o_t 确定性地计算得到。模拟器仅保留隐藏的提取序列，以便后续揭示新的优先级并生成状态转移；策略及其动作选择过程均不得查询该隐藏序列。

令 $c_t^\star = \sigma_{n_t+1}$ 表示当前目标箱，s_t 表示该目标箱所在的堆栈。仅当 $c_t^\star$ 被阻挡时，环境才请求策略作出决策。因此，每个决策时刻需要移动的集装箱是唯一确定的，即堆栈 s_t 顶部的集装箱；策略动作只需选择目的堆栈。若 $h_j(X_t)$ 表示布局 X_t 中堆栈 j 的当前高度，则可行动作集合为

$$\mathcal{A}(o_t) = \{j \in \{1,\ldots,S\} : j \neq s_t,\ h_j(X_t) < T\}. \tag{4}$$

本文仅考虑在每个重定位决策时刻至少存在一个可行目的堆栈的实例。执行动作 $a_t \in \mathcal{A}(o_t)$ 后，阻挡箱被放置到堆栈 a_t 的顶部。随后，环境连续提取所有已经可达且顺序相邻的目标箱，并按照提取数量公开相同数量的新优先级，直至再次需要重定位或全部集装箱均已提取。

策略 π 根据公开观测及其合法动作掩码，输出目的堆栈上的概率分布，并满足

$$\pi(a_t \mid o_t) = 0 \quad \text{对于所有 } a_t \notin \mathcal{A}(o_t). \tag{5}$$

由于每次策略决策恰好执行一次重定位，本文将即时奖励设为 $r_t = -1$。令 $\tau(I,\pi)$ 表示策略 π 求解实例 I 时，从初始状态到终止状态所经历的重定位决策数量。总重定位成本为

$$R(I;\pi) = -\sum_{t=0}^{\tau(I,\pi)-1} r_t = \tau(I,\pi). \tag{6}$$

对于实例分布 $\mathcal{D}$，学习目标定义为期望重定位率

$$J_{\mathcal{D}}(\pi) = \mathbb{E}_{I\sim\mathcal{D},\, a_t\sim\pi}\left[\frac{R(I;\pi)}{N_I}\right], \qquad \pi^\star \in \arg\min_{\pi} J_{\mathcal{D}}(\pi). \tag{7}$$

其中，先对每个实例的重定位次数进行归一化再求平均，可以防止规模较大的实例在总体指标中获得不成比例的权重。本文同时报告未经归一化的重定位次数，但不将其视为一个独立的优化目标。

1.2 目标域策略适配问题

令 π_{θ_0} 表示在源分布 $\mathcal{D}_{\text{src}}$ 上训练得到的策略。本文使用有限的适配数据集和受控的梯度更新次数，将该固定基础策略适配到目标分布 $\mathcal{D}_{\text{tgt}}$。在当前研究中，目标分布包含满足 $N \in [100,150]$、$S \in [20,25]$、$T \in \{8,10\}$ 的布局，可行填充率位于 60% 至 80% 之间，并固定 $H = 20$。由于源分布与目标分布可能同时在集装箱数量、贝位形状和填充率方面存在差异，该

设定构成复合分布偏移。因此，若缺少额外的受控实验，观察到的性能增益不能被单独归因于问题规模的变化。

对于选定的线性层集合 $\mathcal{L}$，低秩适配将每个冻结的基础权重矩阵 $W_\ell^0 \in \mathbb{R}^{d_{\text{out}} \times d_{\text{in}}}$ 重新参数化为

$$W_\ell(\phi) = W_\ell^0 + \frac{\alpha}{r} B_\ell A_\ell, \qquad A_\ell \in \mathbb{R}^{r \times d_{\text{in}}}, \quad B_\ell \in \mathbb{R}^{d_{\text{out}} \times r}, \quad \ell \in \mathcal{L}, \tag{8}$$

其中，秩 r 远小于相应的输入维度和输出维度，训练期间仅优化 $\phi = \{A_\ell, B_\ell\}_{\ell \in \mathcal{L}}$ [3]。可训练参数数量为

$$P(\mathcal{L}, r) = \sum_{\ell \in \mathcal{L}} r \left(d_{\text{in}}^\ell + d_{\text{out}}^\ell \right). \tag{9}$$

适配问题旨在寻找线性层集合及其低秩更新，使目标域上的期望重定位率在参数预算与更新预算的约束下达到最小：

$$(\mathcal{L}^\star, \phi^\star) \in \arg\min_{\mathcal{L}, \phi} J_{\mathcal{D}_{\text{tgt}}}\left(\pi_{\theta_0, \phi}^{\mathcal{L}}\right) \quad \text{s.t.} \quad \theta_0 \text{ 保持冻结}, \; P(\mathcal{L}, r) \le P_{\max}, \; U \le U_{\max}, \tag{10}$$

其中，U 表示实际执行的梯度更新次数。在实验中，本文比较以下低秩更新位置：仅更新解码器的查询投影；更新解码器的上下文、查询和键投影；以及在上述解码器投影之外进一步更新编码器最后一个前馈网络模块。本文还在相同基础策略和相同更新协议下进行全参数微调，并将其作为不限制适配子空间的对照方法。本文的核心问题是：改变适配子空间与训练长度能否降低式 (7) 所定义的目标域重定位率。可训练参数量、显存占用、训练时间和推理时间作为次要成本分别报告，而不与重定位率合并为单一目标。

参考文献

[1] E. Zehendner, D. Feillet, and P. Jaillet. An algorithm with performance guarantee for the online container relocation problem. *European Journal of Operational Research*, 259(1):48–62, 2017. doi:10.1016/j.ejor.2016.09.011.

[2] W.-J. Shin, I. Choi, S.-H. Cho, and H.-J. Kim. Learning to retrieve containers: A scale-diverse deep reinforcement learning approach for the container retrieval problem. *Transportation Research Part C: Emerging Technologies*, 183:105496, 2026. doi:10.1016/j.trc.2025.105496.

[3] E. J. Hu, Y. Shen, P. Wallis, Z. Allen-Zhu, Y. Li, S. Wang, L. Wang, and W. Chen. LoRA: Low-rank adaptation of large language models. In *International Conference on Learning Representations*, 2022. `https://openreview.net/forum?id=nZeVKeeFYf9`.